数据仓库与数据挖掘复习题

1. 假设数据挖掘的任务是将如下的 8 个点（用（x,y）代表位置）聚类为 3 个类：X1(2,10)、X2(2,5)、X3(8,4)、X4(5,8)、X5(7,5)、X6(6,4)、X7(1,2)、X8(4,9)，距离选择欧几里德距离。假设初始选择 X1(2,10)、X4(5,8)、X7(1,2)为每个聚类的中心，请用 K_means 算法来计算：

（1）在第一次循环执行后的 3 个聚类中心；

答：第一次迭代：中心点 1：X1(2，10)，2：X4(5，8)，X7(1，2)

	X1	X2	X3	X4	X5	X6	X7	X8
1	0	25	36+36	9+4	25+25	16+36	1+64	4+1
2	9+4	9+9	9+16	0	4+9	1+16	16+36	1+1
3	1+64	1+9	53	16+36	45	29	0	58

答案：在第一次循环执行后的 3 个聚类中心：

1：X1(2，10)

2：X3，X4，X5，X6，X8　（6，6）

3：X2，X7　（1.5，3.5）

（2）经过两次循环后，最后的 3 个族分别是什么？

第二次迭代：

d^2	X1	X2	X3	X4	X5	X6	X7	X8
1	0	25	36+36	9+4	25+25	16+36	1+64	4+1
2	32	17	8	5	2	4	41	1+1
3	$5^2+6.5^2$	$5^2+1.5^2$	$6.5^2+0.5^2$	$3.5^2+4.5^2$	$5.5^2+1.5^2$	$4.5^2+0.5^2$	$0.5^2+1.5^2$	$2.5^2+5.5^2$

答案：1：X1，X8 (3.5，9.5)

2：X3，X4，X5，X6　（6.5，5.25）

3：X2，X7　（1.5，3.5）

2. 数据库有 4 个事务。设 min_sup=60%,min_conf=80%。

TID	data	Transaction
T100	6/6/2007	K,A,D,B
T200	6/6/2007	D,A,C,E,B
T300	6/7/2007	C,A,B,E
T400	6/10/2007	B,A,D

a.使用 Apriori 算法找出频繁项集，并写出具体过程。

答：

(a)Apriori 算法：

~~**{K} 1**~~ **{A} 4** **{A,B} 4** **{A,B,D} 3**

{A} 4 **{B} 4** **{A,D} 3**

{B} 4 **{D} 3** **{B,D} 3**

{D} 3

~~**{C} 2**~~

~~**{E} 2**~~

频繁项集为 3 项集{A,B,D}:3

b.列出所有的强关联规则，使它们与下面的元规则匹配，其中，X 是代表顾客的变量，$item_i$ 是表示项的变量（例如，“A”、“B”等）：

$$\forall x \in transaction, buys(X, item_1) \wedge buys(X, item_2) \Rightarrow buys(X, item_3) \qquad [s,c]$$

答：所有频繁子项集有{A},{B},{D},{A,B},{A,D},{B,D}

A^B=>D conf=3/4=75% ×

A^D=>B conf=3/3=100% √

B^D=>A conf=3/3=100% √

因此，满足条件的强关联规则有：

A^D=>B{supp=75%,conf=100%}

B^D=>A{supp=75%,conf=100%}

1.给定如下的数据库表：

ID	Sky	AirTemp	Humidity	Wind	Water	Forecast	Enjoysport
1	Sunny	Warm	Normal	Strong	Warm	Same	Yes
2	Sunny	Warm	High	Strong	Warm	Same	Yes
3	Rainy	Cold	High	Strong	Warm	Change	No
4	Sunny	Warm	High	Strong	Cool	Change	yes

请计算属性 Sky 的信息增益。

答：

C1 ：Enjoysport=yes=3

C2 ：Enjoysport=no=1

$I(yes,no)=-3/4\log_2 3/4-1/4\log_2 1/4=0.811$

sky	C1	C2
rainy	0	1
sunny	3	0

I(sky)=1/4I(0,1)+3/4I(3,0)=0

Gain(sky)=0.811

习题:

1. 以汽车保险为例:假定训练数据库具有两个属性:年龄和汽车类型。

年龄————序数属性

汽车类型——分类属性

类————L：低（风险） ，H：高（风险）

年龄	汽车类型	类

>21	Maruti	L
>21	Hyundai	H
<21	Maruti	H
<21	Indica	H
>21	Maruti	L
>21	Hyundai	H

使用 ID3 算法得到一个决策树。

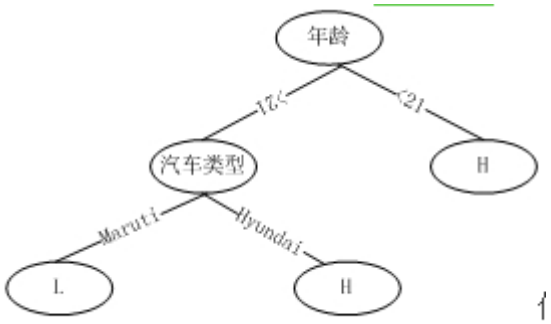

2. 下面是一个超市某商品连续 24 个月的销售数据（单位：百万元）：21，16，21, 19, 24, 27, 23, 22, 21, 20, 17, 16, 20, 23, 22, 18, 24, 26, 25, 20, 26, 23, 21, 15, 17。

   请使用等深、等宽和自定义区间的方法对数据进行分箱，做出利用各种分箱方法得到的直方图。

上述数据所形成属性值/频率对的直方图如图-2.6 所示。

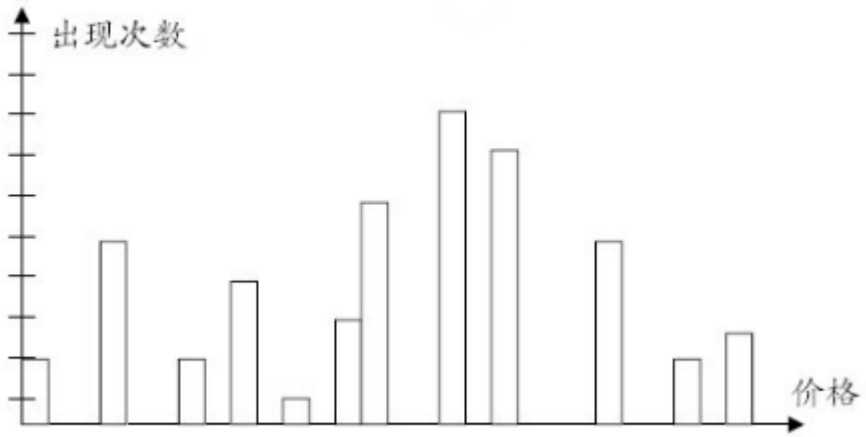

图-2.6 数据直方图描述示意（以 1 元为单位）

3. 数据库有 4 个事务。设 min_sup = 60%，min_conf = 80%。使用

Apriori 算法找出所有的频繁项集，并针对每个频繁项集构造强关联规则，列出每个规则的支持度和置信度。

TID	Date	items_bought
T100	10/15/99	{K, A, D, B}
T200	10/15/99	{D, A, C, E, B}
T300	10/19/99	{C, A, B, E}
T400	10/22/99	{B, A, D}

答：

(b)Apriori 算法：

~~{K} 1~~ {A} 4 {A,B} 4 {A,B,D} 3

{A} 4 {B} 4 {A,D} 3

{B} 4 {D} 3 {B,D} 3

{D} 3

~~{C} 2~~

~~{E} 2~~

频繁项集为 3 项集{A,B,D}:3

所有频繁子项集有{A},{B},{D},{A,B},{A,D},{B,D}

A^B=>D conf=3/4=75% ×

A^D=>B conf=3/3=100% √

B^D=>A conf=3/3=100% √

因此，满足条件的强关联规则有：

A^D=>B{supp=75%,conf=100%}

B^D=>A{supp=75%,conf=100%}